Proyecto AASIM

Fase 2: Preparación de datos, gobernanza y validez (resultados sobre PulseDB v2.0)

Equipo E (Juan Manuel Buitrago, Luis Carlos Rocha, German Alberto Hidalgo)

20 de septiembre de 2026

Objetivo, entregables y alcance

Objetivo: dejar los datos de ECG y presión arterial listos, trazables y libres de fuga de información antes de entrenar modelos en la Fase 3.

Entregables

1. Data Quality Report (DQR)
2. Diccionario de datos y esquema de metadatos
3. Lista y matriz de riesgos de validez
4. Pipeline modular de preprocesamiento

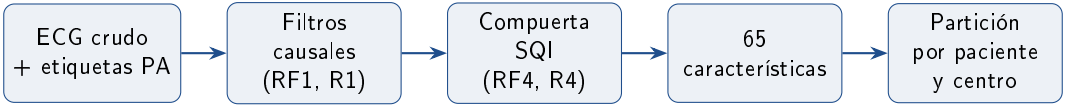
Responsables

- **Buitrago:** validación clínica y comparadores
- **Rocha:** señales, características y particiones
- **Hidalgo:** privacidad, equidad y calidad de señal

Alcance de los resultados

El corpus real es **PulseDB v2.0** (MIMIC-III y VitalDB). Las etiquetas se caracterizaron completas (5 361 sujetos); las formas de onda, sobre una **muestra** de 41 sujetos y 2 042 ventanas. Es un diagnóstico preliminar, no desempeño clínico.

Pipeline de preprocesamiento



- **Filtrado:** pasa-altos Butterworth (0.5 Hz), notch adaptativo a 50/60 Hz con $Q \geq 35$ y pasa-bajos (45 Hz), todo causal y con estado; el modo de fase cero se rechaza en inferencia.
- **Muestreo:** PulseDB entrega ECG a 125 Hz; el mínimo del esquema se ajustó de 250 a 125 Hz (riesgo V-18: resolución de 8 ms por muestra).
- **Etiquetas:** censura clínica de PAS fuera de 70–240 mmHg, PAD fuera de 40–140 mmHg y presión de pulso menor de 20 mmHg.

El corpus: PulseDB v2.0

	MIMIC	VitalDB
Sujetos	2 423	2 938
Segmentos (10 s, 125 Hz)	3 791 004	1 454 450
Edad media (adultos)	63.5	59.2
Mujeres	42 %	45 %
IMC disponible	0 %	100 %
Etiquetas censuradas	3.56 %	1.88 %

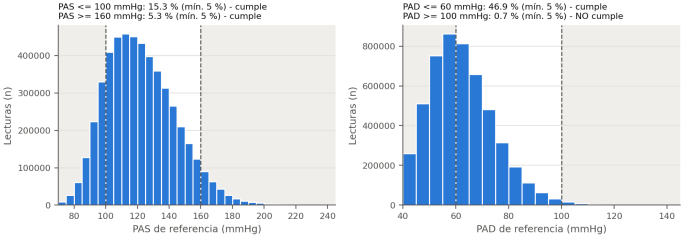
Adultos: 5 332; 43.5 % con 65 años o más.

Límites que condicionan el uso

- Población hospitalaria con catéter arterial.
- Sin postura, medicación ni comorbilidades.
- Solo dos centros.
- Licencias ODbL y CC BY-NC-SA 4.0: revisión legal antes de uso comercial.

Cuotas ISO 81060-2 en las etiquetas

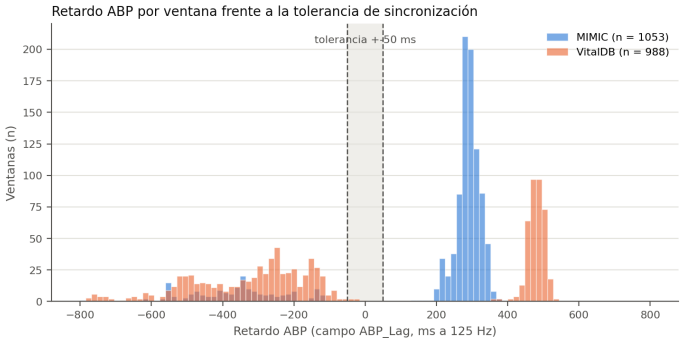
Distribución de las etiquetas de referencia y cuotas ANSI/AAMI/ISO 81060-2



Rango	Fracción	
PAS ≤ 100	15.3 %	**Cumple**
PAS ≥ 160	5.3 %	**Cumple**
PAD ≤ 60	46.9 %	**Cumple**
PAD ≥ 100	0.65 %	**No cumple**

Mínimo exigido: 5 %. VitalDB por sí sola no cumple PAS ≥ 160 (1.9 %); en la partición de prueba, PAS ≥ 160 baja a 4.7 %. El desempeño en la cola diastólica alta no podrá afirmarse.

Sincronización ECG–referencia (supuesto S3)



- Desfase de alineación `ABP_Lag` de PulseDB: mediana +280 ms (MIMIC) y −176 ms (VitalDB).
- **99.7 %** de las ventanas superan la tolerancia de 50 ms.
- El signo cambia dentro de un mismo sujeto en el 27 % de las ventanas consecutivas.

La fuente no garantiza S3. Falta confirmar la definición exacta del campo con la documentación de la base.

Compuerta de calidad de señal (RF4) con datos reales

Umbrales del plan: bSQI ≥ 0.85, kSQI ≥ 5.0, pSQI ≥ 0.50.

Muestra (2 042 ventanas)	n	%
Retenidas	1 109	54.3
Rechazadas	933	45.7
por bSQI	77	3.8
por kSQI	131	6.4
por pSQI	927	45.4

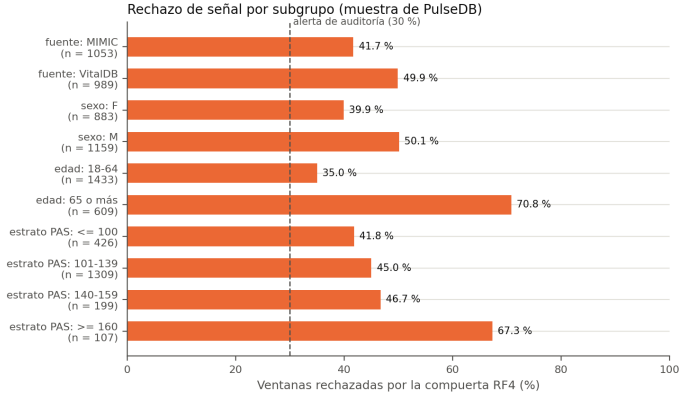
Mediana de pSQI: 0.52 (MIMIC) y 0.50 (VitalDB): el umbral cae sobre la mediana.

Sensibilidad exploratoria del umbral de pSQI

pSQI	Global	18–64	≥65	Cociente
0.50	45.7	35.0	70.8	2.0
0.40	22.8	12.8	46.5	3.6
0.30	13.2	4.7	33.2	7.1

Hallazgo: bajar el umbral reduce la pérdida, pero aumenta la disparidad por edad. El pSQI mide morfología correlacionada con la edad y debe rediseñarse; los umbrales no se congelan con esta muestra.

Rechazo selectivo por subgrupo (riesgo V-09)



- Edad: 35.0 % (18–64) frente a 70.8 % (65 o más); cociente **2.02**.
- Estrato de PAS: 41.8 % ($\leq$100) a 67.3 % ($\geq$160); cociente **1.61**.
- Sexo 1.26; fuente 1.20.

Criterio de la puerta G8: cociente ≤ 1.5. **No cumple**

Pérdida neta en la muestra: 46.7 % (criterio $< 15\,\%$). Celdas con menos de 5 sujetos agrupadas.

Características y latencia sobre ventanas reales

- 65 características por ventana: morfología, HRV, wavelet Daubechies 4 y textura GLCM.
- QRS 90 ± 15 ms, coherente; PR satura en 264 ms en el 6.5 % de las ventanas; QT y QTc con dispersión alta: a 125 Hz son de **baja fiabilidad**.
- Entropía muestral indefinida en 39.8 % de las ventanas; VLF constante en 10 s.
- Correlación máxima con la presión: $|\rho| = 0.37$ (textura y amplitud del QRS), con posible confusión por ganancia y electrodo.
- Detector de picos R: F1 $= 1.00$ (mediana) frente a las anotaciones de PulseDB.

Latencia (RNF2)

2 041 ventanas reales de 10 s en el equipo de trabajo (2 CPU): media 12.5 ms, percentil 99 43.4 ms, máximo 93.8 ms; margen mínimo de 53 veces frente a 5 s. Se repetirá en el hardware de referencia.

Interferencia de red

Detectada en 34–42 % de las ventanas; el detector marca 50 Hz en VitalDB donde se esperaba 60 Hz: pendiente de verificación.

Particionamiento sin fuga y privacidad

Partición	Sujetos	MIMIC	VitalDB
Entrenamiento	3 732	1 695	2 037
Validación	800	363	437
Prueba	800	363	437

- Estratificada por fuente, edad, sexo y PAS: edad media 61 años y 43.8 % de mujeres en las tres particiones.
- **Certificado:** 0 sujetos y 0 huellas SHA-256 en común; manifiesto sellado.
- Con dos centros no cabe la partición por sitio 70/15/15: se usa *leave-one-site-out*.

Privacidad (RNF1)

Identificadores opacos `SUBJ-xxxxx`; los nombres originales de PulseDB quedan en una tabla de acceso restringido; edad en rangos; celdas con $n < 5$ agrupadas.

Esquema de metadatos 1.1.0

ECG a 125 Hz o más; categorías `not_available` para IMC y postura cuando la fuente no las aporta.

Riesgos de validez: qué confirmaron los datos reales

Riesgo	Evidencia con PulseDB	Estado
Fuga por identidad (V-01)	Partición certificada, 0 intersecciones	Implementado
Sesgo retrospectivo (V-02)	Cadena causal en todo el pipeline; 41 pruebas superadas	Implementado
Colapso hacia la media (V-04)	PAD $\geq$ 100 mmHg: 0.65 % de las lecturas	Crítico
Desalineación temporal (V-05)	99.7 % de ventanas con desfase $>$ 50 ms	Crítico
Rechazo selectivo (V-09)	Cociente 2.02 por edad y 1.61 por PAS	Alto
Umbrales mal calibrados (V-10)	pSQI = 0.50 sobre la mediana; 45.7 % de rechazo	Crítico
Resolución a 125 Hz (V-18)	PR satura; QRS y dV/dt con 8 ms por muestra	Alto
Dominio y licencia (V-19)	Población hospitalaria; CC BY-NC-SA 4.0	Alto

Total: 19 riesgos evaluados por probabilidad y severidad (informe de riesgos).

Puertas de decisión hacia la Fase 3

Puerta	Estado
G1 DQR (pérdida, cuotas)	No cumple
G2 Aislamiento de particiones	Cumple
G3 Latencia	Parcial
G5 Comparador certificado	No cumple
G6 Sincronización	No cumple
G7 Representatividad	Parcial
G8 Rechazo no selectivo	No cumple
G11 Política causal	Cumple

G4, G9 y G10 pendientes; G12 con protocolo implementado.

Decisión del equipo

Con G1 y G5 sin cumplir, la Fase 3 **no queda autorizada**. Rutas propuestas:

1. Rediseñar el índice espectral y recalibrar con *train* y *val*.
2. Acotar por acta una etapa exploratoria sobre datos públicos, sin afirmaciones clínicas.
3. Incorporar un conjunto propio con comparador certificado y sincronización controlada.