Diccionario de Datos y Especificación de Variables del Sistema AASIM

Proyecto AASIM - Fase 2

Juan Manuel Buitrago, Luis Carlos Rocha y German Alberto Hidalgo

19 de septiembre de 2026

Índice general

1. Propósito y alcance **2**
1.1 Convenciones . . . 2
1.2 Códigos de trazabilidad . . . 2

2. Módulo 1 - Procedencia, trazabilidad y privacidad **3**

3. Módulo 2 - Parámetros técnicos de adquisición **3**

4. Módulo 3 - Contexto demográfico y fisiológico **5**

5. Módulo 4 - Referencia y sincronización metrológica **6**

6. Módulo 5 - Control de calidad de la grabación **7**

7. Series temporales, ventanas y etiquetas **7**

8. Índices de calidad de señal y características por ventana **9**
8.1 Índices de calidad (compuerta RF4) . . . 9
8.2 Características morfológicas del ECG (clase 1) . . . 10
8.3 Variabilidad de la frecuencia cardíaca (clase 2) . . . 10
8.4 Paquetes wavelet Daubechies 4 (clase 3) . . . 11
8.5 Texturas GLCM en regiones de interés (clase 4) . . . 11

9. Covariables codificadas para el modelado **12**

10. Reglas de integridad referencial y de dominio transversales **12**

11. Marco de versionado de datos (dirección: Luis Carlos Rocha) **13**
11.1 Principios . . . 13
11.2 Política de numeración semántica (`MAYOR.MENOR.PARCHE`) . . . 13
11.3 Registro de cambios y puertas de publicación . . . 14

12. Protocolo de custodia de llaves de anonimización (dirección: German Alberto Hidalgo) **14**
12.1 Distinción entre seudonimización y anonimización . . . 14
12.2 Roles . . . 14
12.3 Ciclo de vida de la llave . . . 14
12.4 Controles de desidentificación previos a la incorporación (RNF1) . . . 15
12.5 Marco normativo de referencia . . . 15

13. Matriz de trazabilidad requisito - campos **15**

14. Correspondencia con PulseDB v2.0 (fuente de datos de la Fase 2) **16**

15. Control del documento **17**

Proyecto: AASIM - Software como Dispositivo Médico (SaMD) para la estimación continua de PAS, PAD y PAM a partir de derivaciones de electrocardiografía
Fase: 2 - Preparación de Datos, Gobernanza y Mitigación de Riesgos de Validez
Documento: `reports/data_dictionary.md`, versión 1.1.0
Fecha de edición: 20 de septiembre de 2026
Esquema formal asociado: `config/metadata_schema.json` (JSON Schema 2020-12, `schema_version = 1.1.0`)

Área	Responsable	Contribución a este documento
Validación Clínica	Juan Manuel Buitrago	Variables de referencia, rangos hemodinámicos admisibles, reglas de sincronización con el comparador (RF3, R3, S1)
Ingeniería TI	Luis Carlos Rocha	Series temporales, características, tipos de datos, integridad referencial y marco de versionado de datos
Ética y Pacientes	German Alberto Hidalgo	Identificación y privacidad (RNF1), variables demográficas, calidad de señal (RF4) y protocolo de custodia de llaves de anonimización

1. Propósito y alcance

Este documento especifica, campo por campo, todas las variables que circulan por el pipeline de la Fase 2: los metadatos de adquisición por sesión, las series temporales y etiquetas de presión arterial, los índices de calidad de señal, las características extraídas por ventana y las covariables demográficas codificadas. Para cada campo se declaran el tipo de dato, la unidad del Sistema Internacional (SI) o la unidad clínica de uso aceptado, el rango admisible, la obligatoriedad, las reglas de validación e integridad referencial y su trazabilidad frente a los requisitos del sistema (RF1-RF4, RNF1-RNF4).

Las definiciones aquí contenidas son normativas para el código de `src/` y para el esquema `config/metadata_schema.json`; cualquier discrepancia entre ambos y este documento se trata como un defecto de Fase 2 y se resuelve conforme a la sección 11 (versionado).

1.1 Convenciones

Símbolo	Significado
O	Obligatorio en todo registro.
C	Condicional: obligatorio si se cumple la condición indicada en la regla de validación.
Op	Opcional.
Unidades	SI cuando existe; mmHg para presión arterial (unidad clínica de uso aceptado, 1 mmHg = 133.322 Pa); mV para tensión bioeléctrica; kOhm para impedancia; ppm para deriva de reloj.
`NaN`	Valor no determinable en una ventana (por ejemplo, QT cuando hay menos de tres latidos delineables). No se imputa.
Rango admisible	Intervalo de **plausibilidad fisiológica o instrumental**. Un valor fuera de rango genera una marca de plausibilidad y revisión, salvo que la regla indique exclusión automática.

1.2 Códigos de trazabilidad

RF1: procesamiento y extracción de características en tiempo real. RF2: estimación de PAS, PAD y PAM a partir de ECG. RF3: comparación contra dispositivo de referencia certificado. RF4: advertencia de mala calidad y suspensión de la inferencia. RNF1: confidencialidad, seudonimización y protección de datos. RNF2: latencia de extremo a extremo menor o igual a 5 s. RNF3: hardware accesible y de costo razonable. RNF4: robustez ante variabilidad de impedancia y electrodo. Riesgos R1-R4 y supuestos S1-S4 conforme al plan de la Fase 1.

2. Módulo 1 - Procedencia, trazabilidad y privacidad

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`schema_version`	Cadena (SemVer)	-	Constante `1.1.0`	O	Debe coincidir con `$id` del esquema vigente; un valor distinto implica revalidación completa.	RNF1
`subject_id`	Cadena alfanumérica	-	`^SUBJ-[0-9]{5}$`	O	Clave primaria opaca del paciente. Se asigna por permutación aleatoria; **no se deriva de dato identificable alguno**. Único en toda la base. Es la unidad de partición patient-wise.	RNF1, R2
`recording_id`	Cadena alfanumérica	-	`^REC-[0-9]{7}$`	O	Único por sesión. Clave foránea hacia `subject_id` (una sesión pertenece a un solo sujeto; un sujeto puede tener varias sesiones, todas en la misma partición).	RF1, RF3
`dataset_version`	Cadena (SemVer)	-	`^[0-9]+\{}.[0-9]+\{}.[0-9]+$`	O	Versión de la base consolidada; se rige por la sección 11.	RF1
`site_id`	Cadena alfanumérica	-	`^SITE-[0-9]{3}$`	O	Código opaco del centro. Unidad de la partición site-wise; todo `subject_id` pertenece a un único `site_id`.	RNF1, R2, S4
`source_institution`	Cadena	-	2-120 caracteres	O	Institución de origen ya seudonimizada. No se admiten nombres de servicios, médicos ni ubicaciones geográficas más finas que la institución.	RNF1
`anonymization_protocol`	Enumeración	-	`HIPAA_SAFE_HARBOR`, `GDPR_PSEUDONYMISATION`, `HIPAA_SAFE_HARBOR_AND_GDPR_PSEUDONYMISATION`	O	Estándar aplicado antes de incorporar el registro al entorno de desarrollo. Nota: el campo se denomina también `anonymization_standard` en la directiva operativa; el nombre normativo es el del esquema.	RNF1
`custody_key_status`	Enumeración	-	`pseudonymised_key_retained`, `destroyed_irreversible`	O	Estado de la tabla de correspondencia (sección 12). Solo `destroyed_irreversible` autoriza a denominar el registro “anonimizado”; en el otro caso el registro es “seudonimizado”.	RNF1

3. Módulo 2 - Parámetros técnicos de adquisición

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`ecg_sampling_frequency_hz`	Número	Hz	125 a 20 000	O	Mínimo 125 Hz (criterio ratificado por el equipo en la versión 1.1.0 para admitir PulseDB, cuya frecuencia nativa es 125 Hz; las adquisiciones propias deberían mantener 250 Hz o más). Toda ventana se procesa a la frecuencia nativa declarada; el filtro pasa-bajos (45 Hz) y las bandas de los SQI exigen `fs > 90 Hz` con margen. A 125 Hz la resolución temporal es de 8 ms, lo que limita la exactitud de la duración del QRS y de `dV/dt` (véase el riesgo V-18 del informe de riesgos).	RF1, RNF4
`adc_resolution_bits`	Entero	bit	16 a 32	O	Mínimo 16 bits. Define la cuantización mínima usada en la tasa de saturación.	RF1, RNF4
`adc_full_scale_mv`	Número	mV	> 0	Op	Rango pico a pico del ADC. Requerido para calcular `saturation_rate_percentage` en unidades físicas.	RF4, RNF4
`sensor_hardware_model`	Cadena	-	2-120 caracteres	O	Referencia del sensor. Permite auditar variabilidad entre dispositivos.	RNF3
`leads_utilized`	Arreglo de enumeración	-	`I`, `II`, `III`, `aVR`, `aVL`, `aVF`, `V1-V6`; 1 o más, sin repetidos	O	Se prioriza la derivación II.	RF1, RF2
`primary_lead`	Enumeración	-	Igual que arriba	O	**Regla cruzada:** debe pertenecer a `leads_utilized` (verificada en `metadata_validation.py`).	RF1, RF2
`lead_contact_impedance_kohm`	Número	kOhm	0 a 50	O	Impedancia electrodo-piel tolerada; no debe superar 50 kOhm. Valores superiores se rechazan en el esquema.	RNF4, R1
`mains_frequency_hz`	Entero	Hz	50 o 60	O	Frecuencia nominal de red del sitio; inicializa la búsqueda del notch adaptativo (`filters.estimate_mains_frequency`).	RF1, R1
`recording_duration_s`	Número	s	> 0	Op	Duración total; base del cómputo de horas adquiridas para la pérdida neta de señal.	RF1

4. Módulo 3 - Contexto demográfico y fisiológico

Todas las variables de este módulo son datos personales de salud o cuasi-identificadores. Se almacenan con el mínimo nivel de detalle necesario (principio de minimización de RNF1): no se registran fecha de nacimiento, edad exacta, talla, peso ni fechas absolutas.

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`age_bracket`	Enumeración	años	`18-29`, `30-39`, `40-49`, `50-59`, `60-69`, `70-79`, `80-89`, `90+`	O	Estrato decenal. La categoría `90+` agrupa edades extremas para evitar reidentificación (Safe Harbor). Para el escalado numérico se usa el punto medio del estrato.	R2, S4
`biological_sex`	Enumeración	-	`female`, `male`, `intersex`	O	Sexo biológico. Se codifica con One-Hot.	R2, S4
`bmi_category`	Enumeración	kg/m²	`underweight`, `normal`, `overweight`, `obese_class_1`, `obese_class_2`, `obese_class_3`, `not_available`	O	Clasificación OMS. `not_available` se usa cuando la fuente no aporta talla y peso (MIMIC en PulseDB). Para el escalado numérico se usa un valor representativo por categoría; `not_available` se imputa con 22.0 kg/m² y se marca con el indicador `bmi__not_available`.	R2, RNF4
`posture`	Enumeración	-	`supine`, `seated`, `standing`, `ambulatory`, `not_available`	O	Postura durante el trazado (`not_available` si la fuente pública no la registra). Modifica la presión hidrostática y el tono autonómico; se usa como factor de ajuste. Las lecturas de referencia y el ECG deben compartir la misma postura.	RF2, RF3
`active_cardiovascular_medication`	Arreglo de enumeración	-	`beta_blocker`, `ace_inhibitor`, `arb`, `calcium_channel_blocker`, `diuretic`, `other_cardiovascular`, `unknown`	O	Lista vacía significa sin medicación. `unknown` es excluyente (si aparece, `maxItems = 1`). Codificación multi-hot.	RF2, R2
`known_arrhythmias`	Arreglo de enumeración	-	`atrial_fibrillation`, `atrial_flutter`, `ventricular_ectopy`, `conduction_block`, `other`, `unknown`	O	Lista vacía significa sin arritmias conocidas; `unknown` es excluyente. La presencia de fibrilación o flúter invalida las suposiciones de ritmo sinusal de los descriptores HRV; se reporta en el DQR por separado.	RF2, R2

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`hypertension_status_baseline`	Enumeración	-	`normal`, `elevated`, `stage_1`, `stage_2`, `hypertensive_crisis`, `unknown`	Op	Clasificación AHA/ACC basal, usada para la auditoría de cuotas y para la estratificación de la partición.	R2, S4
`comorbidities`	Arreglo de enumeración	-	`diabetes`, `vascular_stiffness`, `intraventricular_conduction_disorder`, `chronic_kidney_disease`	Op	Categorías gruesas para la auditoría de subgrupos protegidos. Ampliar el catálogo exige incremento MENOR del esquema.	R2, S4

5. Módulo 4 - Referencia y sincronización metrológica

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`reference_device_type`	Enumeración	-	`oscillometric_brachial_automatic`, `invasive_intra_arterial_line`, `volume_clamp`	O	Tecnología del comparador. Determina la semántica temporal de la etiqueta (continua o intermitente).	RF3, R3
`reference_device_model`	Cadena	-	2-120 caracteres	O	Marca y modelo.	RF3, S1
`reference_measurement_uncertainty_mmhg`	Número	mmHg	0 a 20	O	Incertidumbre metrológica declarada. Insumo del piso de error irreducible (riesgo V-06 del informe de riesgos).	R3, S1
`reference_validation_standard`	Enumeración	-	`ANSI_AAMI_ISO_81060-2`, `ANSI_AAMI_ISO_81060-3`, `IEEE_1708`, `none_documented`	O	Norma con la que se validó el comparador. **Regla:** `none_documented` es admisible en el esquema pero bloquea la certificación del registro en el DQR (S1).	RF3, S1
`sync_protocol`	Enumeración	-	`PTP`, `NTP`, `hardware_trigger`, `manual_event_alignment`	O	Mecanismo de sincronización de relojes. `manual_event_alignment` exige verificación por correlación de eventos.	S3, R1
`sampling_offset_ms`	Número	ms	0 a < 50	O	Retardo temporal absoluto medido entre las dos señales. Estrictamente inferior a 50 ms.	S3, RF3
`max_timestamp_uncertainty_ms`	Número	ms	0 a 10	O	Incertidumbre máxima de marca temporal por ciclo. Los ciclos con incertidumbre superior a 10 ms se descartan automáticamente.	S3

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`clock_skew_tolerance_ppm`	Número	ppm	0 a < 10	O	Deriva máxima de reloj tolerada. A 10 ppm la deriva acumulada alcanza 10 ms en 1 000 s, lo que fija el intervalo máximo de resincronización (ver informe de riesgos, V-05).	S3

6. Módulo 5 - Control de calidad de la grabación

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`n_windows_total`	Entero	ventanas	>= 0	Op	Número de ventanas evaluadas en la sesión.	RF4
`n_windows_rejected`	Entero	ventanas	>= 0	Op	**Regla cruzada:** menor o igual a `n_windows_total`; corresponde al conteo de `quality_flag = 1`.	RF4
`rejection_ratio_percentage`	Número	%	0 a 100	O	**Regla cruzada:** coincide con `100 * n_windows_rejected / n_windows_total` con tolerancia de 0.1 puntos porcentuales.	RF4, R4
`mean_bsqi_score`	Número	adimensional	0 a 1	O	Promedio del bSQI de la sesión.	RF4
`mean_ksqi_score`	Número	adimensional	>= 0	Op	Promedio de la curtosis fisiológica.	RF4
`mean_psqi_score`	Número	adimensional	0 a 1	Op	Promedio de la potencia espectral relativa.	RF4
`saturation_rate_percentage`	Número	%	0 a 100	Op	Fracción de muestras en los rieles del ADC (`quality_assessment.saturation_fraction`).	RF4, RNF4
`qc_review_required`	Booleano	-	`true`/`false`	O	**Regla condicional del esquema:** si `rejection_ratio_percentage` > 30, debe ser `true` (auditoría clínica individualizada).	RF4, R4

7. Series temporales, ventanas y etiquetas

Estos campos describen las tablas de trabajo generadas por el pipeline (una fila por muestra o por ventana según se indica). No forman parte del esquema JSON de metadatos, pero sus claves foráneas dependen de él.

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`timestamp_rel_ms`	Entero positivo	ms	>= 0	O	Tiempo relativo al inicio de la sesión. Estrictamente monótono creciente; sin fechas absolutas (Safe Harbor).	RF1, S3
`ecg_raw_lead_ii`	Punto flotante	mV	Depende de `adc_full_scale_mv`; típico -5 a +5	O	Señal cruda de la derivación II. Nunca se sobrescribe (sección 11). No se aceptan `NaN` fuera de discontinuidades declaradas.	RF1
`ecg_filtered`	Punto flotante	mV	Típico -5 a +5	O	Salida de `filters.apply_filter_chain` en modo **causal** para todo dato destinado a entrenamiento e inferencia. El modo de fase cero solo se admite en auditoría retrospectiva y debe declararse en el registro de procedencia del artefacto.	RF1, R1
`window_id`	Cadena	-	`recording_id` + `:` + índice de ventana	O	Único. Clave foránea hacia `recording_id`.	RF1
`window_start_ms`, `window_end_ms`	Entero	ms	Diferencia entre 10 000 y 30 000	O	Duración de ventana entre 10 y 30 s. Las ventanas nunca cruzan fronteras de sesión ni de sujeto.	RF1, RNF2
`partition`	Enumeración	-	`train`, `val`, `test`	O	Heredada del sujeto (`split_dataset.assign_windows`). Un `subject_id` tiene exactamente una partición.	R2, RNF1
`quality_flag`	Booleano	-	0 válido, 1 rechazo	O	Salida de la compuerta RF4. Si es 1, no se calcula ninguna estimación de presión arterial.	RF4, R4
`sqi_composite`	Punto flotante	adimensional	0 a 1	O	Promedio de `min(1, índice/umbral)` para bSQI, kSQI y pSQI. Vale 1.0 si y solo si los tres criterios se cumplen.	RF4
`ref_systolic_bp`	Punto flotante	mmHg	70 a 240	C	Obligatoria en la partición de entrenamiento, validación y prueba; ausente en inferencia. Se censura fuera de rango (`censor_reference_labels`).	RF3, S1
`ref_diastolic_bp`	Punto flotante	mmHg	40 a 140	C	Ídem. Debe cumplir `ref_systolic_bp - ref_diastolic_bp >= 20`.	RF3, S1

Campo	Tipo	Unidad	Rango / formato admisible	Oblig.	Regla de validación e integridad referencial	Requisitos
`ref_mean_bp`	Punto flotante	mmHg	50 a 180 (referencial)	C	Medida por el comparador; si no está disponible, `PAD + (PAS - PAD) / 3` y se marca `ref_mean_bp_derived = true`.	RF2, RF3
`ref_label_valid`	Booleano	-	`true/false`	O	Resultado de la censura hemodinámica.	RF3, S1
`ref_exclusion_reason`	Enumeración	-	`admisible`, `valor no finito`, `PAS fuera de rango`, `PAD fuera de rango`, `PAS <= PAD`, `presión de pulso inferior al mínimo`, `presión de pulso superior al máximo`	O	Códigos 0-6 de `filters.REASON_LABELS`.	RF3, R3
`ref_unstable_flag`	Booleano	-	`true/false`	Op	Marca de inestabilidad de la referencia (variación de PAS superior a 15 mmHg en 120 s en reposo, `flag_unstable_reference`).	R3, S1
`sync_uncertainty_ms`	Punto flotante	ms	0 a 10	C	Incertidumbre temporal del par ECG-referencia; ciclos con más de 10 ms se descartan.	S3

8. Índices de calidad de señal y características por ventana

8.1 Índices de calidad (compuerta RF4)

Campo	Tipo	Unidad	Rango admisible	Umbral de aceptación	Definición y regla	Requisitos
`bsqi`	Punto flotante	adimensional	0 a 1	>= 0.85	F1 de latidos coincidentes entre Pan-Tompkins y el detector de longitud de curva, tolerancia 50 ms. Cero si ninguno detecta latidos.	RF4, R4
`ksqi`	Punto flotante	adimensional	>= 0	>= 5.0	Curtosis de Pearson (gaussiana = 3) en bloques de 5 s, agregada con la mediana. Ruido incoherente tiende a 3; saturación produce valores subgaussianos.	RF4, R4

Campo	Tipo	Unidad	Rango admisible	Umbral de aceptación	Definición y regla	Requisitos
`psqi`	Punto flotante	adimensional	0 a 1	>= 0.50	Potencia en 5-15 Hz dividida por la potencia en 1-40 Hz (Welch).	RF4, R4
`ssqi`	Punto flotante	adimensional	-	Informativo	Asimetría (tercer momento estandarizado); no interviene en la compuerta.	RF4
`n_beats_pan_tompkins`, `n_beats_curve_length`	Entero	latidos	>= 0	-	Latidos de cada detector; su cociente audita el bSQI.	RF4
`failed_criteria`	Lista de cadenas	-	subconjunto de `bSQI`, `kSQI`, `pSQI`, `no_finito`	-	Causa del descarte, que se comunica al usuario.	RF4, R4
`saturation_fraction`	Punto flotante	fracción	0 a 1	Propuesta: <= 0.01 por sesión (a ratificar)	Fracción de muestras en los rieles del ADC.	RF4, RNF4
`flatline_fraction`	Punto flotante	fracción	0 a 1	Reporte	Fracción de la señal en tramos planos de 0.5 s o más.	RF4, RNF4

Regla de la compuerta: `quality_flag = 0` si y solo si `bsqi >= 0.85`, `ksqi >= 5.0` y `psqi >= 0.50`; en cualquier otro caso `quality_flag = 1`.

8.2 Características morfológicas del ECG (clase 1)

Campo	Unidad	Rango de plausibilidad	Definición	Requisitos
`feat_pr_interval_ms`	ms	60 a 400	Inicio de la onda P a inicio del QRS; mediana de latidos. `NaN` si la onda P no se detecta.	RF2
`feat_qrs_duration_ms`	ms	40 a 200	Inicio a fin del complejo QRS por umbral de pendiente.	RF2
`feat_qt_interval_ms`	ms	200 a 650	Inicio del QRS a fin de la onda T (método de la tangente).	RF2
`feat_qtc_bazett_ms`	ms	250 a 700	`QT / sqrt(RR)`, RR en s (RR previo).	RF2
`feat_qtc_fridericia_ms`	ms	250 a 700	`QT / RR^(1/3)`, RR en s.	RF2
`feat_dvdt_max`	mV/s	> 0	Pendiente máxima ascendente de la onda R (unidades de ECG por segundo). Correlaciona con contractilidad.	RF2
`feat_s_depth_mv`	mV	-3 a 0.5	Profundidad de la onda S respecto de la línea isoeléctrica.	RF2
`feat_st_deviation_mv`	mV	-1 a 1	Desviación del segmento ST a 60 ms del fin del QRS.	RF2
`feat_r_amplitude_mv`	mV	0.1 a 5	Amplitud de la onda R sobre la línea isoeléctrica.	RF2, RNF4
`feat_t_amplitude_mv`	mV	-2 a 2	Amplitud de la onda T (con signo).	RF2

Los valores se calculan en unidades físicas; la normalización robusta se aplica aguas abajo y solo con estadísticos de entrenamiento.

8.3 Variabilidad de la frecuencia cardíaca (clase 2)

Campo	Unidad	Rango de plausibilidad	Definición	Requisitos
`feat_hrv_mean_nn_ms`	ms	300 a 2 000	Promedio de intervalos NN aceptados.	RF2
`feat_hrv_sdnn_ms`	ms	0 a 500	Desviación estándar de NN (ddof = 1).	RF2
`feat_hrv_rmssd_ms`	ms	0 a 500	Raíz de la media cuadrática de diferencias sucesivas.	RF2
`feat_hrv_pnn50_pct`	%	0 a 100	Porcentaje de diferencias sucesivas mayores a 50 ms.	RF2
`feat_hrv_vlf_ms2`	ms²	>= 0	Potencia 0.0033-0.04 Hz. **Baja fiabilidad en ventanas menores a 250 s.**	RF2
`feat_hrv_lf_ms2`	ms²	>= 0	Potencia 0.04-0.15 Hz. Fiabilidad limitada en ventanas cortas.	RF2
`feat_hrv_hf_ms2`	ms²	>= 0	Potencia 0.15-0.40 Hz.	RF2
`feat_hrv_lf_hf`	adimensional	>= 0	Cociente LF/HF; `NaN` si HF = 0.	RF2
`feat_hrv_sd1_ms`, `feat_hrv_sd2_ms`	ms	>= 0	Semiejes de la elipse de Poincaré.	RF2
`feat_hrv_sampen`, `feat_hrv_apen`	adimensional	0 a 3.5	Entropía muestral y aproximada (m = 2, r = 0.2 DE). `NaN` si no hay coincidencias.	RF2

Los intervalos RR fuera de 300-2 000 ms o desviados más de 20 % de la mediana local se excluyen y **no se interpolan**. Se exigen al menos 8 intervalos NN válidos; en caso contrario toda la clase HRV queda en `NaN`.

8.4 Paquetes wavelet Daubechies 4 (clase 3)

Con nivel de descomposición `L = 4` (configurable) se obtienen `2^L = 16` subbandas ordenadas por frecuencia, cada una de ancho `fs / 2^(L+1)` Hz.

Campo	Cantidad	Rango	Definición	Requisitos
`feat_wpd_e_00` … `feat_wpd_e_15`	16	[0, 1]; suman 1	Energía relativa de la subbanda.	RF2
`feat_wpd_h_00` … `feat_wpd_h_15`	16	[0, 1]	Entropía de Shannon normalizada de la distribución de energía de los coeficientes de la subbanda.	RF2
`feat_wpd_entropy_total`	1	[0, ln 16]	Entropía wavelet de la distribución de energía entre subbandas.	RF2

8.5 Texturas GLCM en regiones de interés (clase 4)

El espectrograma (STFT, ventana de Hann de 192 ms, salto de 16 ms, `nfft = 256`) se expresa en escala logarítmica y se cuantiza a 16 niveles con los percentiles 1-99 de la propia ventana. Las ROI son: complejo QRS (10-30 Hz, ±60 ms alrededor de R) y onda T (1-7 Hz, de 150 a 400 ms después de R). Las matrices de co-ocurrencia (distancia 1; 0°, 45°, 90° y 135°) se acumulan entre latidos.

Campo	Cantidad	Rango	Definición	Requisitos
`feat_glcm_qrs_contrast`, `feat_glcm_t_contrast`	2	0 a 225	Contraste.	RF2

Campo	Cantidad	Rango	Definición	Requisitos
`feat_glcm_qrs_correlation`, `feat_glcm_t_correlation`	2	-1 a 1	Correlación; `NaN` si la varianza es nula.	RF2
`feat_glcm_qrs_energy`, `feat_glcm_t_energy`	2	(0, 1]	Raíz cuadrada del ASM.	RF2
`feat_glcm_qrs_homogeneity`, `feat_glcm_t_homogeneity`	2	(0, 1]	Homogeneidad.	RF2
`feat_glcm_qrs_asm`, `feat_glcm_t_asm`	2	(0, 1]	Momento angular de segundo orden.	RF2

El vector completo tiene **65 características** con el orden fijado por `extract_features.feature_names()`. Los tiempos de cómputo por etapa se reportan en `FeatureResult.latency_ms` (RNF2).

9. Covariables codificadas para el modelado

Columna generada	Origen	Codificación	Ajuste	Requisitos
`age_years_mid`	`age_bracket`	Punto medio del estrato, escalado robusto (mediana, IQR)	Solo con entrenamiento	RF2, R2
`bmi_representative`	`bmi_category`	Valor representativo por categoría, escalado robusto	Solo con entrenamiento	RF2, RNF4
`sex__female`, `sex__male`, `sex__intersex`	`biological_sex`	One-Hot con categorías fijas del esquema	No aplica	RF2, R2
`posture__supine`, `posture__seated`, `posture__standing`, `posture__ambulatory`, `posture__not_available`	`posture`	One-Hot con categorías fijas	No aplica	RF2
`med__beta_blocker`, `med__ace_inhibitor`, `med__arb`, `med__calcium_channel_blocker`, `med__diuretic`, `med__other_cardiovascular`, `med__unknown`	`active_cardiovascular_medication`	Multi-hot	No aplica	RF2
`bmi__not_available`	`bmi_category`	Indicador binario de IMC imputado	No aplica	RF2, R2

Una categoría fuera del esquema lanza un error (no crea una columna nueva), de modo que la dimensión de entrada no depende del contenido de los conjuntos de validación o prueba.

10. Reglas de integridad referencial y de dominio transversales

ID	Regla	Verificación	Consecuencia del incumplimiento
INT-01	`subject_id` es único y cada `recording_id` referencia exactamente un `subject_id`.	Validador de esquema y pruebas de partición	Rechazo del registro
INT-02	Todos los registros y ventanas de un `subject_id` pertenecen a una sola partición.	`assign_windows`, `assert_no_cross_partition_subjects`	`DataLeakageError`
INT-03	Los conjuntos `train`, `val` y `test` tienen intersección vacía de sujetos, verificada sobre identificadores y huellas SHA-256 con sal.	`assert_disjoint_subjects`	`DataLeakageError`
INT-04	En la partición site-wise, ningún `site_id` aparece en más de una partición.	`assert_disjoint_sites`	`DataLeakageError`
INT-05	Los estadísticos de normalización (mediana, IQR, escalado de covariables, pesos de estrato) se ajustan solo con filas de `train`.	`TrainOnlyRobustScaler.fit`, `assert_scaler_train_only`	`DataLeakageError`
INT-06	`timestamp_rel_ms` es estrictamente creciente dentro de cada `recording_id`.	Verificación de ingesta	Rechazo de la sesión
INT-07	`primary_lead` pertenece a `leads_utilized`.	`metadata_validation.validate_metadata`	Rechazo del registro
INT-08	`rejection_ratio_percentage` es coherente con los conteos de ventanas.	`metadata_validation.validate_metadata`	Rechazo del registro
INT-09	Si `rejection_ratio_percentage` > 30, `qc_review_required = true`.	Esquema (condicional `if/then`)	Rechazo del registro
INT-10	Ninguna etiqueta de referencia se usa como entrada de característica; `ref_mean_bp` derivado no puede entrar al conjunto de predictores.	Revisión de esquema de características (`feature_names`)	Bloqueo de la Fase 3
INT-11	Cada ventana usa solo muestras de ECG anteriores o iguales al instante de su etiqueta (ventana de cola).	Revisión de código y pruebas de causalidad	Bloqueo de la Fase 3

11. Marco de versionado de datos (dirección: Luis Carlos Rocha)

11.1 Principios

1. **Inmutabilidad de lo crudo.** Los archivos de `data/raw/` no se modifican ni se sobrescriben; toda corrección genera un artefacto derivado en `data/processed/` con su propia versión.
2. **Trazabilidad completa.** Cada artefacto derivado registra: versión del conjunto de datos de origen, huella SHA-256 de cada archivo de entrada, versión del esquema, versión del código (identificador de confirmación del repositorio), parámetros de configuración (`FilterConfig`, `SQIThresholds`, `FeatureConfig`, `SplitConfig` con su semilla) y modo de filtrado (causal o fase cero).
3. **Reproducibilidad.** La misma versión de datos, de código y de configuración produce byte a byte el mismo resultado; las particiones son deterministas (hash SHA-256 de `semilla:sujeto`) e independientes del orden de las filas.
4. **Separación de particiones.** El manifiesto de partición se sella (`seal_manifest`) y su huella se publica en el registro de versiones; una modificación posterior lo invalida (`verify_seal`).

11.2 Política de numeración semántica (`MAYOR.MENOR.PARCHE`)

Componente	Se incrementa cuando…	Ejemplo	Efecto sobre los resultados aguas abajo
MAYOR	Cambia el esquema de forma incompatible, se altera la definición de una etiqueta o de una característica, se modifica la política de censura o de partición.	Cambiar el límite de PAS de censura	Todo modelo y reporte previo queda obsoleto y debe recalcularse

Componente	Se incrementa cuando…	Ejemplo	Efecto sobre los resultados aguas abajo
MENOR	Se incorporan sujetos, sesiones o campos opcionales nuevos sin alterar los existentes.	Ingesta de un nuevo centro	Recalcular particiones si cambia la cohorte; los sujetos previos conservan su partición
PARCHE	Se corrigen errores de formato o metadatos que no alteran señales ni etiquetas.	Corrección tipográfica de `sensor_hardware_model`	Ninguno

Regla de estabilidad de particiones. Al añadir sujetos (incremento MENOR) los sujetos ya asignados **conservan** su partición; los nuevos se asignan por el mismo mecanismo determinista. Un sujeto jamás cambia de partición entre versiones, porque ello contaminaría los conjuntos de prueba ya evaluados.

11.3 Registro de cambios y puertas de publicación

Toda versión se publica con: notas de cambio, lista de huellas de archivos, resultado de la validación de esquema (porcentaje de registros válidos), certificado de aislamiento (`SplitCertificate`) y resumen del DQR. Una versión no se publica si el porcentaje de registros que validan contra el esquema es inferior al 100 % o si el certificado de aislamiento no pudo emitirse.

12. Protocolo de custodia de llaves de anonimización (dirección: German Alberto Hidalgo)

12.1 Distinción entre seudonimización y anonimización

El identificador `subject_id` es un código opaco asignado por permutación aleatoria sin derivación desde datos personales; por sí solo no permite reidentificar al paciente. Mientras exista una tabla de correspondencia entre el identificador original y `subject_id`, el conjunto de datos es **seudonimizado** en el sentido del RGPD (artículo 4, numeral 5): reversible para quien custodia la tabla y, por tanto, sigue sujeto a la normativa de protección de datos. Solo tras la **destrucción verificada** de la tabla y de toda copia el conjunto puede considerarse **anonimizado de forma irreversible**, y únicamente entonces `custody_key_status` toma el valor `destroyed_irreversible`.

12.2 Roles

Rol	Responsabilidad	Restricción
Custodio de llaves (dirección de Ética y Pacientes)	Genera, custodia y destruye la tabla de correspondencia; autoriza toda reidentificación excepcional.	No tiene acceso de escritura al repositorio de código ni a los modelos.
Custodio suplente	Ejerce el control dual con el custodio principal.	Designado por el comité de ética institucional; distinto de los integrantes de ingeniería.
Equipo de ingeniería (Ingeniería TI)	Procesa exclusivamente datos ya seudonimizados.	Sin acceso a la tabla ni a las llaves, ni a los sistemas donde se almacenan.
Validación Clínica	Puede solicitar una reidentificación clínica excepcional (por ejemplo, un hallazgo incidental relevante).	Toda solicitud se tramita ante el custodio y queda registrada.

12.3 Ciclo de vida de la llave

Etapa	Requisito
Generación	La permutación y cualquier sal criptográfica se generan con un generador criptográficamente seguro. Los identificadores no se derivan de números de historia clínica, documentos ni fechas.
Almacenamiento	La tabla se cifra con AES-256 y se almacena en un repositorio físicamente y lógicamente separado del entorno de desarrollo, con control de acceso por doble autorización (conocimiento dividido entre dos custodios).
Uso	Solo se accede a la tabla para la asignación inicial de identificadores y para reidentificaciones autorizadas. Cada acceso se registra (quién, cuándo, motivo, autorización); el registro es de solo anexado.
Copias	Se prohíben copias no inventariadas. Todas las copias autorizadas figuran en el inventario del custodio.
Rotación	Ante sospecha de compromiso se declara incidente, se notifica al comité de ética y se evalúa la reasignación de identificadores (incremento MAYOR de `dataset_version`).
Congelamiento	Al cerrar la Fase 2 (versión candidata a la Fase 3), el comité decide si la finalidad del estudio aún exige conservar la tabla.
Destrucción	Si no hay finalidad que justifique conservarla, se destruye la tabla y todas sus copias mediante borrado criptográfico (destrucción de la clave de cifrado) y sobrescritura de los medios. Se levanta un acta firmada por ambos custodios con las huellas de los medios afectados. Solo entonces se actualiza `custody_key_status`.

12.4 Controles de desidentificación previos a la incorporación (RNF1)

Control	Aplicación
Identificadores directos	Eliminación de nombres, documentos, contactos, números de historia clínica, direcciones y cualquier identificador biométrico distinto del propio ECG.
Fechas	Sustitución por tiempo relativo (`timestamp_rel_ms`); no se conservan fechas absolutas de atención.
Edad	Estratos decenales; las edades de 90 años o más se agrupan en `90+`.
Geografía	Solo el código opaco del centro (`site_id`); nada más fino.
Riesgo de reidentificación por combinación	Antes de cualquier informe o compartición se verifica que cada combinación de covariables (edad, sexo, centro, comorbilidad) tenga al menos 5 sujetos; las celdas menores se suprimen o se agrupan.
ECG como dato biométrico	La morfología del ECG es casi identificadora; el registro de señal cruda solo se comparte bajo acuerdo de uso de datos y nunca junto con la tabla de correspondencia.

12.5 Marco normativo de referencia

El protocolo se elabora tomando como referencia el método Safe Harbor de HIPAA y el RGPD. Para el contexto colombiano deben confirmarse con el comité de ética institucional los requisitos aplicables de la Ley 1581 de 2012 (protección de datos personales) y de la Resolución 8430 de 1993 (investigación en salud). Este documento no constituye asesoría jurídica; la interpretación de la normativa es responsabilidad de la instancia institucional competente.

13. Matriz de trazabilidad requisito - campos

Requisito	Campos y módulos principales
RF1	`ecg_raw_lead_ii`, `ecg_filtered`, `timestamp_rel_ms`, `window_*`, `ecg_sampling_frequency_hz`, `adc_resolution_bits`, todas las `feat_*`
RF2	Todas las `feat_*`, covariables codificadas, `posture`, `active_cardiovascular_medication`, `known_arrhythmias`
RF3	`ref_*`, `reference_*`, `sync_protocol`, `sampling_offset_ms`, `max_timestamp_uncertainty_ms`, `clock_skew_tolerance_ppm`, `ref_label_valid`, `ref_unstable_flag`
RF4	`quality_flag`, `sqi_composite`, `bsqi`, `ksqi`, `psqi`, `ssqi`, `failed_criteria`, `saturation_fraction`, módulo 5 completo
RNF1	`subject_id`, `recording_id`, `site_id`, `anonymization_protocol`, `custody_key_status`, `age_bracket`, sección 12
RNF2	`FeatureResult.latency_ms`, `benchmark_latency`; `window_start_ms`/`window_end_ms` (ventanas de 10-30 s)

Requisito	Campos y módulos principales
RNF3	`sensor_hardware_model`, dependencias limitadas a NumPy, SciPy y PyWavelets
RNF4	`lead_contact_impedance_kohm`, `saturation_rate_percentage`, `flatline_fraction`, `feat_r_amplitude_mv`, normalización robusta mediana/IQR
R1	`mains_frequency_hz`, cadena de filtros de `filters.py`
R2, S4	`age_bracket`, `biological_sex`, `bmi_category`, `hypertension_status_baseline`, `comorbidities`, `partition`, estratos de PAS
R3, S1	`reference_measurement_uncertainty_mmhg`, `reference_validation_standard`, `ref_unstable_flag`
R4	`quality_flag`, `failed_criteria`, mensajes al usuario
S3	`sampling_offset_ms`, `sync_uncertainty_ms`, `clock_skew_tolerance_ppm`

14. Correspondencia con PulseDB v2.0 (fuente de datos de la Fase 2)

Dirección: Luis Carlos Rocha (mapeo técnico) y German Alberto Hidalgo (privacidad). La fuente pública PulseDB v2.0 (MIMIC-III y VitalDB; 5 361 sujetos y 5 245 454 segmentos de 10 s a 125 Hz) se incorporó mediante `src/ingestion/pulsedb_catalog.py` y `src/ingestion/pulsedb_sample.py`. La tabla siguiente indica qué campo del diccionario se puede poblar y cuáles no.

Campo del diccionario	Origen en PulseDB	Estado
`subject_id`	Permutación aleatoria (`SUBJ-xxxxx`); nombre original solo en la tabla de correspondencia restringida	Disponible
`site_id`	`SITE-001` (MIMIC), `SITE-002` (VitalDB)	Disponible (solo dos centros)
`age_bracket`	`Subj_Age` (edad exacta, agrupada en bandas decenales)	Disponible
`biological_sex`	`Subj_Gender`	Disponible (femenino, masculino)
`bmi_category`	`Subj_BMI` solo en VitalDB	Parcial: `not_available` en MIMIC (0 % de disponibilidad)
`ecg_sampling_frequency_hz`	125 Hz (fija)	Disponible; cumple el mínimo de 125 Hz de la versión 1.1.0
`ref_sbp_mmhg`, `ref_dbp_mmhg`	`SegSBP`, `SegDBP` (presión arterial invasiva)	Disponible
`sampling_offset_ms`	`ABP_Lag` (muestras x 8 ms), cuya definición debe confirmarse	Disponible con reservas (véase el DQR, sección 3.3)
`posture`, `active_cardiovascular_medication`, `known_arrhythmias`, `comorbidities`, `hypertension_status_baseline`	No incluidos	No disponible (`not_available` o `unknown`)
`lead_contact_impedance_kohm`, `sensor_hardware_model`, `adc_resolution_bits`, `adc_full_scale_mv`, `mains_frequency_hz`	No incluidos (ECG normalizado por PulseDB)	No disponible
`reference_measurement_uncertainty_mmhg`, `reference_validation_standard`, `sync_protocol`, `max_timestamp_uncertainty_ms`, `clock_skew_tolerance_ppm`	No incluidos	No disponible

Consecuencia para la puerta G4. Varios campos obligatorios del esquema 1.1.0 (impedancia, modelo de sensor, resolución del ADC, incertidumbre del comparador, norma de validación,

protocolo de sincronización, incertidumbre temporal y deriva de reloj) no se pueden poblar con datos reales de PulseDB sin inventar valores, y el equipo decidió no hacerlo. La conformidad del 100 % con el esquema queda por ello **pendiente**: se propone (Rocha, Hidalgo) un perfil de fuente pública en una versión MENOR posterior, con esos campos opcionales y un marcador explícito de origen, para no debilitar el esquema de las adquisiciones propias. En la versión 1.1.0 se añadieron las categorías `not_available` (IMC y postura) y se aceptó `unknown` en la codificación de la medicación.

Privacidad. Los nombres originales de PulseDB (`p000160_0`) y las marcas temporales de caso no se exportan al catálogo analítico; se guardan en `data/metadata/tabla_correspondencia_RESTRINGIDA.csv` con permisos restringidos, conforme a la sección 12. **Licencias:** ODbL (MIMIC) y CC BY-NC-SA 4.0 (VitalDB); el uso comercial requiere revisión legal (riesgo V-19).

---

15. Control del documento

Versión	Fecha	Descripción	Responsables
1.0.0	2026-09-19	Primera edición para la Fase 2, alineada con `metadata_schema.json` 1.0.0 y los módulos de `src/`.	Buitrago, Rocha, Hidalgo
1.1.0	2026-09-20	Mínimo de muestreo del ECG en 125 Hz; categorías `not_available`; codificación de `unknown` en medicación; sección 14 de correspondencia con PulseDB v2.0. Esquema 1.1.0.	Buitrago, Rocha, Hidalgo

Aprobación del diccionario de datos y del esquema de metadatos (criterio 4 de las puertas hacia la Fase 3: coherencia e integridad de campos, descriptores y etiquetas de calibración).

Nombre	Rol	Firma	Fecha
Juan Manuel Buitrago	Validación Clínica y Criterios Hemodinámicos	_____	___ / ___ / _____
Luis Carlos Rocha	Infraestructura, Algoritmos TI y Preprocesamiento	_____	___ / ___ / _____
German Alberto Hidalgo	Ética Médica, Privacidad y Control de Calidad	_____	___ / ___ / _____