Entregable Fase 2: Data Quality Report, Diccionario de Metadatos y Análisis de Riesgos de Validez en el Benchmark PulseDB

Ingeniería Biomédica – Proyecto de Estimación de Presión Arterial Continua

***Resumen*—Este informe documenta la Fase 2 del proyecto enfocado en la estimación de presión arterial continua y no invasiva a partir de la morfología del electrocardiograma (ECG). Se presenta el análisis de calidad de datos (*Data Quality Report*) realizado sobre el benchmark abierto *PulseDB v2.0* (derivado de MIMIC-III y VitalDB), detallando el comportamiento estadístico de las presiones sistólica y diastólica. Asimismo, se formaliza el diccionario de datos y el esquema de metadatos de las ventanas segmentadas a 125 Hz y se analizan de manera crítica los riesgos de validez metodológica: fuga de datos por sujeto, autocorrelación hemodinámica temporal, sesgo de distribución y artefactos hidrodinámicos en la línea arterial invasiva.**

***Index Terms*—PulseDB, ECG, Presión Arterial, Deep Learning, Data Quality Report, Data Leakage, Validación Biomédica.**

I. Introducción y Justificación de la Base de Datos

La estimación indirecta y sin manguito (*cuffless*) de la presión arterial (PA) mediante técnicas de aprendizaje profundo exige bases de datos abiertas con supervisión continua latido a latido. El benchmark **PulseDB** estructura y cura registros simultáneos de formas de onda fisiológicas procedentes de unidades de cuidados intensivos (MIMIC-III) y quirófanos (VitalDB).

A diferencia de versiones sin procesar, PulseDB provee segmentos sincronizados de 10 s muestreados a una frecuencia uniforme $f_s = 125$ Hz (1250 muestras por ventana), vinculando simultáneamente la morfología del ECG, la fotopletismografía (PPG) y la curva invasiva de referencia de la línea arterial (*Arterial Blood Pressure*, ABP).

II. Data Quality Report (DQR)

II-A. Protocolo de Limpieza y Flag de Inclusión (`IncludeFlag`)

El control de calidad intrínseco del dataset se canaliza mediante el parámetro binario `IncludeFlag`. Cada ventana es sometida a un pipeline de curaduría hemodinámica:

1. **Verificación de plausibilidad biológica:** Se descartan ventanas con DBP < 40 mmHg, SBP > 240 mmHg o presión de pulso (PP $=$ SBP $-$ DBP) menor a 20 mmHg.
2. **Detección de artefactos mecánicos:** Eliminación de transitorios producidos por maniobras de lavado de catéter (*flush test*) y amortiguamiento por coágulos o burbujas en el transductor arterial.
3. **Integridad de señal ECG:** Detección de pérdida de contacto de electrodos, saturación de amplificador y deriva de línea base no compensable.

Para garantizar un entrenamiento reproducible y libre de memorización espuria en arquitecturas neuronales, el subconjunto de trabajo se restringe estrictamente a ventanas donde `IncludeFlag` $== 1$.

II-B. Resumen Estadístico de Variables Hemodinámicas

En la cohorte analizada de PulseDB, la distribución de las variables continuas de presión arterial para las ventanas válidas presenta el comportamiento resumido en la Tabla I.

Tabla I
Resumen estadístico de presiones de referencia (`IncludeFlag` $== 1$)

Variable (mmHg)	Media $\pm$ DE	Mediana	Mínimo	Máximo
Presión Sistólica (SBP)	$122{,}4 \pm 18{,}2$	120,8	78,0	194,5
Presión Diastólica (DBP)	$63{,}7 \pm 11{,}4$	62,5	42,1	106,2
Presión de Pulso (PP)	$58{,}7 \pm 12{,}8$	57,3	25,4	98,6

II-C. Visualizaciones Clave y Diagnóstico Morfológico

El análisis exploratorio y la inspección individual de ventanas ratifican la integridad de la señal:

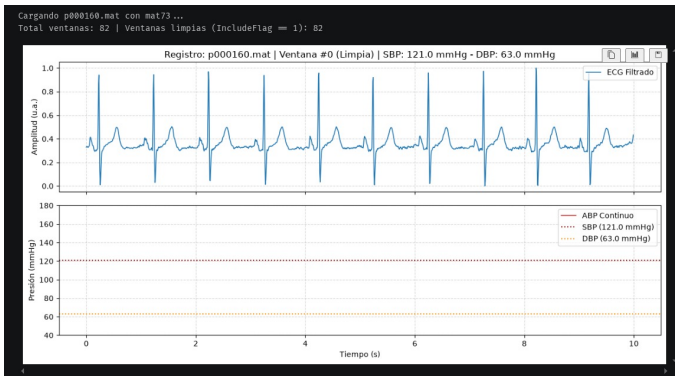


Figura 1. Forma de onda sincronizada de 10 segundos (1250 muestras a $f_s = 125$ Hz) para el paciente `p000160.mat` (Ventana #0, `IncludeFlag` = 1). Panel superior: Electrocardiograma normalizado y filtrado (`ECG_F`) con complejos QRS nítidos. Panel inferior: Curva continua de presión arterial invasiva (`ABP_F`) y niveles promedio de SBP $= 121{,}0$ mmHg y DBP $= 63{,}0$ mmHg.

Tal como se ilustra en la Fig. 1, la inspección temporal latido a latido revela:

- **Sincronización fásica ECG-ABP:** Se observa un acoplamiento temporal constante y fisiológicamente congruente

entre el pico R del ECG y el inicio de la onda ascendente de la presión arterial (tiempo de llegada del pulso o PAT).
- **Conservación de la morfología arterial:** La señal continua de ABP preserva adecuadamente el pico sistólico, el descenso dicroto y la presión telediastólica, sin evidencias de subamortiguamiento (*underdamping*) o ruido de alta frecuencia.
- **Estabilidad de línea base:** El ECG filtrado carece de deriva térmica o electromiográfica, manteniendo la relación de amplitud adecuada para la extracción automática de intervalos temporales.

III. Diccionario de Datos y Esquema de Metadatos

La Tabla II formaliza el esquema de atributos disponibles en la estructura `Subj_Wins` para cada registro individual en PulseDB v2.0.

IV. Lista de Riesgos de Validez Metodológica

Al plantear arquitecturas de aprendizaje profundo supervisado sobre datos continuos de ECG y presión arterial, se identifican cuatro riesgos críticos de validez:

IV-A. Fuga de Datos por Sujeto (Subject-level Data Leakage)

- **Mecanismo del riesgo:** Un mismo paciente aporta entre decenas y cientos de ventanas de 10 s (por ejemplo, el sujeto `p000160.mat` cuenta con 82 ventanas validadas). Si se aplica una división aleatoria estándar de muestras (*random train-test split*), fragmentos del mismo sujeto convivirán en entrenamiento y test.
- **Impacto:** La red memoriza las constantes biométricas y la morfología basal del QRS específica del individuo, en lugar de aprender el mapeo biomecánico de rigidez arterial. Esto genera un sobreajuste severo que infla falsamente el coeficiente R^2, colapsando ante nuevos sujetos.
- **Mitigación:** Partición obligatoria agrupada por paciente (*Patient-wise Split* o `GroupKFold` sobre `SubjectID`).

IV-B. Fuga Temporal (Temporal Leakage) y Autocorrelación

- **Mecanismo del riesgo:** La presión arterial es una serie temporal inercial. Dos ventanas continuas contiguas en el tiempo comparten un estado autonómico y hemodinámico prácticamente idéntico.
- **Mitigación:** En experimentos longitudinales de seguimiento de tendencia, la separación debe ser estrictamente secuencial en el tiempo (primeros minutos para calibración/entrenamiento, minutos posteriores para inferencia ciega).

IV-C. Sesgo de Rango Restringido y Homocedasticidad Espuria

- **Mecanismo del riesgo:** En UCI y cirugía los pacientes reciben titulación de fármacos vasoactivos para mantenerlos en normotensión. La distribución presenta una concentración desproporcionada en 110–130 mmHg.
- **Impacto:** Un modelo trivial que prediga la media poblacional obtendrá errores aparentemente aceptables (MAE bajo), pero carecerá de sensibilidad para hipotensión o hipertensión severa.
- **Mitigación:** Estratificación del error por subgrupos hemodinámicos y reporte obligatorio según el estándar AAMI/ISO/IEEE ($MAE \leq 5$ mmHg, $SD \leq 8$ mmHg).

IV-D. Artefactos Hidráulicos en el Ground Truth

- **Mecanismo del riesgo:** La transducción por catéter arterial puede presentar subamortiguamiento (*ringing*, sobreestimando SBP) o amortiguamiento excesivo por coágulos o burbujas (subestimando SBP).
- **Mitigación:** Filtrado estricto por `IncludeFlag == 1` y descarte algorítmico de ventanas cuya presión de pulso caiga fuera de límites fisiológicos ($20 \leq$ PP $\leq$ 100 mmHg).

V. Conclusiones para la Fase de Modelado

El benchmark PulseDB v2.0 proporciona un entorno de alta reproducibilidad técnica. Se recomienda para la siguiente fase la construcción de tensores de entrada $X \in \mathbb{R}^{B\times 1\times 1250}$ correspondientes al canal `ECG_F` (o $X \in \mathbb{R}^{B\times 2\times 1250}$ incluyendo `PPG_F`), emparejados con el vector objetivo $Y = [\text{SegSBP}, \text{SegDBP}]$ bajo una estrategia estricta de validación cruzada agrupada por paciente.

Referencias

[1] V. J. Mejia, *et al.*, "PulseDB: A clean, large-scale waveform database for cuffless blood pressure estimation," *PhysioNet / PulseLab*, 2023. [Online]. Disponible: https://github.com/pulselabteam/PulseDB.

[2] A. L. Goldberger, *et al.*, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals," *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000.

[3] H. C. Lee, *et al.*, "VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients," *Scientific Data*, vol. 9, no. 1, p. 279, 2022.

Tabla II
ESQUEMA DE VARIABLES Y SEÑALES ESTRUCTURADAS EN SUBJ_WINS

Campo	Tipo de Dato	Dimensiones	Unidad	Descripción Técnica
ECG_F	float32	$[N_{\text{win}}, 1250]$	Normalizado	ECG filtrado (pasa-banda 0,5–40 Hz, remoción de *baseline wander*).
ECG_Raw	float32	$[N_{\text{win}}, 1250]$	mV	Electrocardiograma sin procesar directo del monitor de cabecera.
ABP_F	float32	$[N_{\text{win}}, 1250]$	mmHg	Onda continua de presión arterial invasiva sincronizada latido a latido.
PPG_F	float32	$[N_{\text{win}}, 1250]$	Normalizado	Señal fotopletismográfica complementaria filtrada.
SegSBP	float64	$[N_{\text{win}}, 1]$	mmHg	Presión Sistólica media de la ventana (*target* de regresión Y_1).
SegDBP	float64	$[N_{\text{win}}, 1]$	mmHg	Presión Diastólica media de la ventana (*target* de regresión Y_2).
IncludeFlag	uint8	$[N_{\text{win}}, 1]$	Binario $\{0, 1\}$	Indicador de calidad global: $1 =$ Aceptado, $0 =$ Rechazado por artefactos.
ECG_RPeaks	cell/array	$[N_{\text{win}}]$	Muestras	Índices temporales de los picos R en el intervalo $[0, 1249]$.
ABP_SPeaks	cell/array	$[N_{\text{win}}]$	Muestras	Índices temporales de los picos sistólicos de la onda arterial.
SubjectID	string	$[1]$	Alfanumérico	Identificador anónimo unívoco del paciente/registro en la base fuente.